

DEEP-PIPELINE

E-Ticaret Semantik Arama ve
Veri Mühendisliği Ekosistemi
Sistem Tasarım Raporu (PDR)

TEKNOFEST 2026 — E-Ticaret Hackathonu

Tarih: 18.06.2026

Takım: Deep-Pipeline

1. Proje Özeti

Deep-Pipeline, e-ticaret platformlarındaki ürün arama sürecini yeniden tanımlayan, uçtan uca bir semantik arama ve veri mühendisliği ekosistemidir. Proje, kullanıcıların doğal dilde girdikleri arama sorgularını anlamlandırarak, en uygun ürünlerle eşleştirir. Geleneksel anahtar kelime tabanlı (keyword-based) arama motorlarının aksine, Deep-Pipeline doğal dil işleme (NLP) ve derin öğrenme (Deep Learning) tekniklerini kullanarak semantik anlam çıkarması yapar.

Sistem, Teacher-Student Distillation mimarisi sayesinde büyük dil modellerinin doğruluğunun (BGE-M3) küçük ve hızlı modellere (DistilBERTurk) aktarılmasını sağlar. Sonuç olarak, milisaniye seviyesinde yanıt süresiyle yüksek doğruluklu sonuçlar sunar.

2. Problem Durumu ve Çözüm

2.1 Problem

E-ticaret platformlarında günlük milyonlarca arama sorgusu gerçekleştirilmektedir. Bu sorguların büyük çoğunluğu yazım hataları, eksik bilgiler veya belirsiz ifadeler içerir. Örneğin, bir kullanıcı 'siyah deri erkek cüzdan' ararken, 'Derimod Hakiki Deri Cüzdanlık' ürününü bulamayabilir. Bu durum, hem kullanıcı deneyimini olumsuz etkiler hem de platformların gelir kaybı yaşamasına neden olur.

Mevcut sistemlerin karşılaştığı temel sorunlar şunlardır:

- Yazım hatalarına karşı duyarlılık (Örnek: 'aypon' vs 'Apple')
- Marka-ürün uyumsuzluğu (brand mismatch)
- Aksesuar ve ana ürün karışıklığı (accessory confusion)
- Kategoriler arası yanlış eşleşmeler (cross-category errors)
- Düşük hatırlanabilirlik (recall) oranı nadir kategorilerde

2.2 Çözüm: Deep-Pipeline Ekosistemi

Deep-Pipeline, bu problemleri beş ana modülle çözer: (1) Zemberek/Zeyrek tabanlı Türkçe metin ön işleme, (2) RapidFuzz ile fuzzy marka eşleştirme, (3) Hard Negative Mining ile zorlayıcı eğitim örnekleri, (4) Teacher-Student Distillation (Margin-MSE) ile bilgi aktarımı, (5) Kategori bazlı dinamik eşik değer (threshold) optimizasyonu.

3. Yöntem (Methodology)

3.1 Veri Seti ve Ön İşleme

Yarışma kapsamında sağlanan e-ticaret veri seti, arama sorguları ve ürün bilgilerini (başlık, marka, kategori) içerir. Her bir sorgu-ürün çifti, 0 (Alakasız), 1 (Kısmen Alakalı) veya 2 (Çok Alakalı) olarak etiketlenmiştir. Veri ön işleme pipeline'ı şunları kapsar:

- Türkçe özel küçük harf dönüşümü (İ/i ve I/ı çakışması)
- Noktalama işaretlerinin çıkarılması
- SymSpell ile yazım hatası düzeltme (typo correction)
- Zeyrek (Zemberek) ile morfolojik analiz ve lemmatizasyon

3.2 Model Mimarisi

Sistemin çekirdeğinde Cross-Encoder mimarisi bulunmaktadır. Cross-Encoder, sorgu ve ürün metnini tek bir girdi olarak alır ([CLS] sorgu [SEP] ürün [SEP]) ve doğrudan relevans skorunu üretir. Bu yaklaşım, Bi-Encoder modellerine kıyasla çok daha yüksek doğruluk sağlamaktadır.

Teacher Model: BGE-M3 (BAAI) — Çok dilli, yüksek kapasiteli model.

Student Model: DistilBERTurk — Hızlı, Türkçe odaklı hafif model.

Distillation Loss: Margin-MSE (Pairwise ranking sinyali).

Ensemble: CatBoost + LightGBM + Cross-Encoder soft voting.

3.3 Hard Negative Mining

Modelin gerçek dünyada karşılaşacağı en zor senaryolara hazırlanması için üç tip hard negative örneği kullanılmaktadır: (1) Aynı kategoriye ait fakat farklı markadan ürünler (In-Category), (2) BM25 ile yüksek kelime örtüşme oranına sahip ancak alakasız ürünler, (3) Rassal negatif örnekler (baseline).

3.4 Teacher-Student Distillation (Margin-MSE)

Bilgi aktarımı (Knowledge Distillation) sürecinde, büyük Teacher model (BGE-M3) tarafından üretilen soft-label'lı öğrenci model (öğrenci) taklit etmeye çalışır. Ancak klasik MSE loss yerine Margin-MSE kullanılmaktadır. Margin-MSE, iki ürün arasındaki skor farkının (margin) Teacher ve Student modellerinde tutarlı olmasını hedefler.

Final Loss = $\alpha \times \text{CrossEntropyLoss} + (1 - \alpha) \times \text{MarginMSELoss}$

$\alpha = 0.7$ (base_config.yaml'ı değiştirerek ayarlanabilir)

4. Sistem Tasarımı ve Mimari

Proje, modüler ve konfigürasyon odaklı (config-driven) bir mimari üzerine inşa edilmiştir. Tüm deney parametreleri YAML dosyalarından okunur, bu sayede kod değişikliği yapmadan yüzlerce farklı deney konfigürasyonu test edilebilir.

4.1 Dosya Yapısı

```
deep-pipeline/  
  configs/  
    base_config.yaml      # Ana konfigürasyon  
    model/distilberturk.yaml  
  src/  
    data/preprocessor.py   # Metin ön işleme  
    features/brand_features.py # Fuzzy eşleştirme  
    models/cross_encoder.py # PyTorch modeli  
    training/distillation.py # Teacher-Student  
    experiment/tracker.py   # MLflow entegrasyonu  
    experiment/config_loader.py # YAML çözümleyici  
  scripts/  
    run_experiment.py       # Deney başlatıcı  
    run_benchmark.py        # Benchmark testleri  
    run_dashboard.py        # Streamlit XAI  
  deep-pipeline-web/        # Next.js 3D sunum sitesi  
  Dockerfile                # Offline dağıtım  
  requirements.txt
```

4.2 Dağıtım ve Offline Çalışma

Yarışmanın final aşamasında modellerin internet erişimi olmayan bir cihazda çalıştırılması gerekmektedir. Bu gereksinimi karşılamak için Docker tabanlı bir dağıtım stratejisi benimsenmiştir. Dockerfile içerisinde TRANSFORMERS_OFFLINE=1 ve HF_DATASETS_OFFLINE=1 ortam değişkenleri tanımlanmış olup, model ağırlıkları lokal olarak /app/local_model dizininden yüklenmektedir.

5. Yenilikçi (İnovatif) Yön

Deep-Pipeline, aşağıdaki yönleriyle literatürün ve mevcut çözümlerin ötesine geçmektedir:

- Margin-MSE Distillation: Klasik MSE yerine pairwise ranking sinyali taşıyan Margin-MSE loss fonksiyonu ile Teacher-Student aktarımı. Bu, öğrenci modelin sadece skor tahmini değil, ürünler arası sıralama bilgisini de öğrenmesini sağlar.
- Konfigürasyon Odaklı MLOps: Tek bir YAML değişikliği ile model tipi, öğrenme oranı, distillation katsayısı, threshold değerleri ve veri seti yollarını değiştirme imkanı. Bu, yarışmada günlük 50+ deney yapmaya olanak tanır.
- Açıklanabilir Yapay Zeka (XAI) Dashboard: Streamlit tabanlı interaktif panel ile modelin her bir kararının arkasındaki özelliklerin (fuzzy skor, semantik benzerlik, kategori uyumu) şeffaf şekilde gösterilmesi.
- Brutalist 3D Web Deneyimi: Three.js ve Framer Motion ile tasarlanan, projenin teknik derinliğini görsel olarak ileten, Teknik/Basit mod geçişi ile farklı kitlelere hitap eden sunum.

6. Test ve Performans Metrikleri

Sistem performansı aşağıdaki metrikler üzerinden ölçülecektir. Yarışma veri seti henüz açıklanmadığı için bu raporda kanıtsız skor veya benchmark iddiası sunulmamaktadır. Nihai değerler organizatör verisi ve final test ortamı sonrası doldurulacaktır:

Macro F1-Score: Kaggle public/private leaderboard sonrası doldurulacak

Inference Time: Final servis testi sonrası doldurulacak

VRAM/RAM Kullanımı: Final donanım testi sonrası doldurulacak

QPS: Stress test sonrası doldurulacak

Doğrulama stratejisi olarak 5-fold StratifiedKFold kullanılacaktır. Her fold için Precision, Recall, F1-Score ve Confusion Matrix raporlanacaktır. Nihai skor, 5 seed ile Multi-Seed Ensemble ortalaması olarak hesaplanacaktır.

7. Uygulanabilirlik ve Yaygın Etki

Deep-Pipeline'in ürettiği semantik arama modeli, Türkiye'deki tüm e-ticaret platformlarına (Trendyol, Hepsiburada, n11 vb.) entegre edilebilir yapıdadır. FastAPI üzerinden sunulan REST API sayesinde, mevcut arama altyapılarına minimum değişikliklerle eklenebilir.

Projenin sosyal etkisi:

- Kullanıcı deneyiminin iyileşmesi (daha doğru sonuçlar)
- E-ticaret platformlarının gelir artışı (azalan bounce rate)
- Türkçe NLP alanında açık kaynak katkı
- Küçük/orta ölçekli e-ticaret sitelerine erişilebilir AI çözümü

8. Proje Takvimi

Faz 1 (Haziran 2026): Altyapı kurulumu, MLOps pipeline, config sistemi.

Faz 2 (26 Haziran — 15 Temmuz): Veri analizi, baseline model eğitimi.

Faz 3 (15 Temmuz — 15 Ağustos): Hard Negative Mining, Distillation.

Faz 4 (15 Ağustos — 1 Eylül): Ensemble, threshold optimizasyonu.

Faz 5 (1 — 15 Eylül): Final submitleri, rapor ve sunum hazırlık.

9. Riskler ve Acil Durum Planı

Potansiyel riskler ve B planları:

- Risk: Veri setinin dengesiz olması (class imbalance). Plan B: Focal Loss ve class weighting uygulanacak.
- Risk: Modelin overfitting yapması. Plan B: Dropout artırımı, data augmentation ve early stopping.
- Risk: Final cihazında GPU bulunmaması. Plan B: ONNX Runtime ile CPU-optimized inference.

10. Referanslar

- [1] Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. EMNLP.
- [2] Hofstatter, S. et al. (2021). Efficiently Teaching an Effective Dense Retriever with Balanced Topic Aware Sampling. SIGIR.
- [3] Khattab, O. & Zaharia, M. (2020). ColBERT: Efficient and Effective Passage Search via Contextualized Late Interaction. SIGIR.
- [4] Chen, J. et al. (2024). BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity. arXiv:2402.03216.
- [5] Schweter, S. (2020). BERTurk — BERT models for Turkish. Zenodo. doi:10.5281/zenodo.3770924.
- [6] Akbik, A. et al. (2019). FLAIR: An Easy-to-Use Framework for State-of-the-Art NLP. NAACL.